

Politechnika Warszawska
Wydział Elektroniki i Technik Informacyjnych

Statystyka w Analizie Danych
czerwiec 2026

Projekt 2

Testy zgodności rozkładu średniej z rozkładem normalnym
oraz detekcja słabego sygnału w szumie

Autorzy:

Mikołaj Garbowski, nr albumu 325157
Bartłomiej Dmitruk, nr albumu 324911

Warszawa, 2026

Spis treści

1	Problem 1 - CTG, kontynuacja Projektu 1	2
1.1	Metoda rozwiązywania problemu	2
1.1.1	Sformułowanie zadania i wybór rozkładu	2
1.1.2	Parametry eksperymentu (n oraz K)	2
1.1.3	Schemat symulacji i estymacja mocy	2
1.1.4	Kontrola błędu I rodzaju	3
1.1.5	Estymacja skośności i kurtozy	3
1.1.6	Implementacja i powtarzalność	3
1.2	Wyniki	3
1.2.1	Ilustracja zbieżności $\bar{X}_n$ do rozkładu normalnego	3
1.2.2	Moc testów normalności	4
1.2.3	Estymacja skośności i kurtozy nadmiarowej $\bar{X}_n$	8
1.3	Interpretacja wyników i wnioski	9
2	Problem 2 - odbiornik znanego sygnału	10
2.1	Zadanie, założenia	10
2.2	Statystyka testowa	11
2.3	Rozkład statystyki testowej	12
2.3.1	Rozkład Y	12
2.3.2	Rozkład T	12
2.4	Poziom istotności i wartość krytyczna	12
2.5	Moc testu	13
2.6	Symulacje	14
2.7	Moc testu przy słabym sygnale ($A \ll \sigma^2$)	15
2.8	Koncepcja systemu alarmowego	16
2.9	Koncepcja systemu telekomunikacyjnego	16

1 Problem 1 - CTG, kontynuacja Projektu 1

1.1 Metoda rozwiązania problemu

1.1.1 Sformułowanie zadania i wybór rozkładu

Zadanie polega na ilościowym ujęciu zbieżności rozkładu średniej arytmetycznej $\bar{X}_n$ niezależnych zmiennych losowych do rozkładu normalnego, wynikającej z Centralnego Twierdzenia Granicznego. O ile w pierwszej części projektu zbieżność ta była pokazywana w sposób obrazowy (histogramy, estymatory jądrowe, dystrybuanty empiryczne, wykresy kwantyl-kwantyl), o tyle w tym problemie należy zbadać ją za pomocą statystycznych testów zgodności i porównać moce trzech klasycznych narzędzi: testu Kołmogorowa-Smirnowa, testu Shapiro-Wilka oraz testu D'Agostino. Wynikiem porównania ma być wskazanie, który test najskuteczniej wykrywa odchylenia rozkładu $\bar{X}_n$ od rozkładu normalnego w analizowanym przypadku. Uzupełnienie analizy stanowi estymacja skośności i kurtozy nadmiarowej $\bar{X}_n$ jako wielkości, na których wprost opiera się statystyka testu D'Agostino.

Wybór rozkładu bazowego padł na rozkład wykładniczy z parametrem $\lambda = 1$, czyli $X \sim \text{Exp}(1)$. Decyzja ta wynika z dwóch przesłanek. Po pierwsze, rozkład wykładniczy jest silnie skośny (skośność równa 2) i ma kurtozę nadmiarową 6, dzięki czemu odchylenie $\bar{X}_n$ od rozkładu normalnego dla małych n jest wyraźne, a jednocześnie zanika w znanym tempie. Po drugie, wszystkie istotne momenty są dane wzorami analitycznymi ($\mu = 1$, $\sigma^2 = 1$, $\text{Skew}(\bar{X}_n) = 2/\sqrt{n}$, $\text{ExcessKurt}(\bar{X}_n) = 6/n$), co pozwala bezpośrednio porównać estymaty empiryczne z teorią.

1.1.2 Parametry eksperymentu (n oraz K)

Strukturę eksperymentu opisują dwa różne parametry. Liczba uśrednianych zmiennych n wyznacza próbkę, której średnia ma być testowana - jej rosnące wartości odpowiadają coraz lepszemu dopasowaniu $\bar{X}_n$ do rozkładu normalnego. Liczba średnich K , podawana na wejście pojedynczego testu, opisuje, ile niezależnych realizacji $\bar{X}_n$ test otrzymuje naraz; im większe K , tym silniejszy test (lepsza zdolność wykrycia odchylenia). Zgodnie z zaleceniem projektowym przyjęto $K = 50$. Liczba uśrednianych zmiennych przyjmuje wartości $n \in \{2, 3, 5, 7, 10, 15, 20, 30, 50, 70, 100, 200, 500\}$, co pokrywa całą strefę przejścia od małych prób, gdzie odchylenie od normalności jest wyraźne, aż do prób, dla których żaden z testów nie potrafi już rozróżnić $\bar{X}_n$ od $N(\mu, \sigma^2/n)$.

1.1.3 Schemat symulacji i estymacja mocy

Schemat pojedynczej symulacji wygląda następująco. Dla ustalonego n generowanych jest K niezależnych prób o liczności n z rozkładu $\text{Exp}(1)$ i z każdej obliczana jest średnia arytmetyczna. Otrzymany wektor K średnich stanowi wejście dla trzech testów normalności. Test Kołmogorowa-Smirnowa stosujemy w wariancie z w pełni określoną hipotezą zerową: standaryzowane średnie porównujemy z dystrybuantą $N(0, 1)$, przyjmując znane teoretyczne parametry μ oraz σ . Test ma wtedy dokładny rozmiar, różni się jednak od dwóch pozostałych metod, które badają złożoną hipotezę normalności z parametrami szacowanymi wewnątrznie z próby; do konsekwencji tej różnicy wracamy w interpretacji wyników. Test Shapiro-Wilka opiera się na statystyce porównującej kombinację liniową statystyk pozycyjnych z wariancją próby i jest powszechnie uznawany za jeden z najmocniejszych testów normalności w niewielkich próbach. Test D'Agostino-Pearsona (statystyka K^2) łączy dwa składniki: jeden zależy od skośności, drugi od kurtozy, dzięki czemu test wprost

wykrywa najczęstsze formy odejścia od normalności. Całość powtórzono 10 000 razy dla każdej wartości n , a frakcję odrzuceń hipotezy zerowej przy poziomie istotności $\alpha = 0,05$ przyjęto jako estymator mocy.

1.1.4 Kontrola błędu I rodzaju

Aby zweryfikować poprawność implementacji oraz upewnić się, że wszystkie trzy testy utrzymują nominalny poziom istotności, równoległe przeprowadzono symulację kontrolną. W tej wersji K średnich generowano bezpośrednio z rozkładu normalnego $N(0, 1)$ - hipoteza zerowa jest wtedy prawdziwa, a frakcja odrzuceń powinna być bliska α . Odchylenia od 0,05 większe niż wynikające z błędu Monte Carlo wskazywałyby na problem z implementacją lub niewłaściwą standaryzacją w teście Kołmogorowa-Smirnowa.

1.1.5 Estymacja skośności i kurtozy

Estymację skośności i kurtozy nadmiarowej $\bar{X}_n$ przeprowadzono osobno, używając 100 000 niezależnych realizacji średniej dla każdej wartości n . Empiryczne wartości momentów porównano z formułami teoretycznymi $\text{Skew}(\bar{X}_n) = 2/\sqrt{n}$ i $\text{ExcessKurt}(\bar{X}_n) = 6/n$, właściwymi dla bazowego rozkładu $\text{Exp}(1)$. Spadek skośności jak $1/\sqrt{n}$ oraz kurtozy jak $1/n$ odpowiada za stopniowy zanik mocy testu D'Agostino, którego statystyka właśnie z tych dwóch wielkości jest zbudowana.

1.1.6 Implementacja i powtarzalność


Symulacje zaimplementowano w języku Python z wykorzystaniem bibliotek `numpy` oraz `scipy.stats`; testy wywołują funkcje `kstest`, `shapiro` i `normaltest`. Wszystkie generatory liczb pseudolosowych zainicjalizowano oddzielnymi ziarnami pochodnymi od stałej `SEED = 42`, dzięki czemu wyniki są w pełni powtarzalne.

1.2 Wyniki

1.2.1 Ilustracja zbieżności $\bar{X}_n$ do rozkładu normalnego

Punktem wyjścia analizy jest wizualne potwierdzenie, że standaryzowana średnia $Z_n = (\bar{X}_n - \mu)/(\sigma/\sqrt{n})$ rzeczywiście zbiega do $N(0, 1)$ wraz ze wzrostem n . Rysunek 1 przedstawia w górnym rzędzie histogramy gęstości Z_n uzyskane ze 100 000 niezależnych realizacji dla czterech wybranych wartości $n \in \{2, 10, 50, 200\}$, a w dolnym - odpowiadające im wykresy kwantyl-kwantyl względem rozkładu $N(0, 1)$. Dla $n = 2$ histogram zachowuje wyraźną prawostronną skośność dziedziczną z rozkładu wykładniczego: wartość modalna leży po lewej stronie zera, prawy ogon jest znacznie wydłużony, a wykres kwantyl-kwantyl odchyła się od prostej w obu krańcach, najmocniej w prawym ogonie. Dla $n = 10$ asymetria histogramu wyraźnie się zmniejsza, a wykres kwantyl-kwantyl niemal pokrywa się z prostą w centralnej części, odchylenia pozostają jednak widoczne w prawym ogonie. Przy $n = 50$ histogram jest praktycznie symetryczny i bardzo dobrze odpowiada krzywej gęstości $N(0, 1)$, a wykres kwantyl-kwantyl tworzy linię praktycznie nieodróżnialną od idealnej diagonal. Dla $n = 200$ dopasowanie jest tak dobre, że żadnym z dwóch sposobów nie sposób gołym okiem stwierdzić odejścia od normalności - i właśnie tu pojawia się potrzeba zastosowania testów statystycznych, które jako jedyne dają obiektywną, ilościową odpowiedź na pytanie, czy odchylenie jest jeszcze wykrywalne.


Zbieżność rozkładu $\bar{X}_n$ do $N(0,1)$ dla rozkładu bazowego Exp(1)
Liczba prób na n : 100 000



Rysunek 1: Zbieżność standaryzowanej średniej $Z_n = (\bar{X}_n - \mu)/(\sigma/\sqrt{n})$ z rozkładu bazowego Exp(1) do rozkładu $N(0, 1)$. Górny rząd: histogramy gęstości na tle teoretycznej krzywej $N(0, 1)$. Dolny rząd: wykresy kwantyl-kwantyl względem rozkładu $N(0, 1)$.

1.2.2 Moc testów normalności


Centralny wynik pracy stanowi porównanie mocy trzech testów. Rysunek 2 pokazuje empiryczną frakcję odrzuceń hipotezy zerowej w funkcji liczby uśrednianych zmiennych n , przy stałym $K = 50$ i $\alpha = 0,05$. Wszystkie trzy krzywe są monotonicznie malejące - wraz ze wzrostem n rozkład $\bar{X}_n$ coraz lepiej naśladuje rozkład normalny, więc testom jest coraz trudniej wykryć odchylenie od $N(\mu, \sigma^2/n)$.



Rysunek 2: Moc testów normalności (frakcja odrzuceń H_0) dla średniej $\bar{X}_n$ z rozkładu Exp(1), $K = 50$, $\alpha = 0,05$, 10 000 symulacji.

Już z tego rysunku widać wyraźną hierarchię testów. Test Shapiro-Wilka odrzuca hipotezę zerową przy $n = 2$ w niemal 95% przypadków, podczas gdy test D'Agostino osiąga w tej samej sytuacji moc na poziomie 79%, a test Kołmogorowa-Smirnowa jedynie nieco ponad 24%. Hierarchia ta utrzymuje się we wszystkich badanych wartościach n , choć przewaga testu Shapiro-Wilka nad D'Agostino jest stała i niewielka, natomiast przewaga obu nad testem Kołmogorowa-Smirnowa jest wielokrotna. Dla $n = 50$, czyli przypadku $K = n$, moce testów Shapiro-Wilka i D'Agostino spadają do około 10%, a test Kołmogorowa-Smirnowa rejestruje już wartości w okolicach poziomu istotności - dla próby tej długości żaden z testów praktycznie nie odróżnia $\bar{X}_n$ od rozkładu normalnego.

Blizszy widok strefy przejściowej daje rysunek 3, na którym dodano linię referencyjną na poziomie mocy 0,5. Pozwala on odczytać, dla jakiej wartości n dany test zachowuje co najmniej połowiczną zdolność wykrycia odchylenia. Test Shapiro-Wilka utrzymuje moc powyżej 0,5 do około $n \approx 6$, test D'Agostino nieznacznie krócej - do mniej więcej $n \approx 4$, natomiast moc testu Kołmogorowa-Smirnowa nigdy w badanym zakresie tej granicy nie przekracza i już przy $n = 2$ pozostaje na poziomie ok. 0,24.




Rysunek 3: Strefa przejścia mocy testów normalności w pełnym zakresie pionowym z linią referencyjną na poziomie mocy 0,5, ułatwiającą porównanie tempa zaniku mocy między testami.

Pełne wartości liczbowe mocy testów zebrano w tabeli 1. W tej samej tabeli umieszczono również wyniki kontroli błędu I rodzaju - frakcję odrzuceń przy danych pochodzących z rozkładu $N(0, 1)$, kiedy hipoteza zerowa jest prawdziwa. Wartości te powinny być bliskie nominalnemu poziomowi istotności $\alpha = 0,05$, co rzeczywiście potwierdzają wyniki. Testy Kołmogorowa-Smirnowa i Shapiro-Wilka utrzymują empiryczny rozmiar praktycznie identyczny z nominalnym (różnice mieszczą się w zakresie szumu Monte Carlo), test D'Agostino nieznacznie odrzuca częściej (wartości w przedziale ok. 0,054-0,061). Pełna zgodność z α stanowi potwierdzenie, że standaryzacja w teście Kołmogorowa-Smirnowa oraz cała procedura symulacyjna są zaimplementowane poprawnie, a różnice w mocach widoczne na rysunku 2 wynikają z właściwości samych testów, a nie z błędów implementacyjnego.

Tabela 1: Moc testów normalności dla danych $\bar{X}_n$ z $\text{Exp}(1)$ oraz empiryczny rozmiar testów dla danych z $N(0, 1)$. $K = 50$, $\alpha = 0,05$, 10 000 symulacji.

n	Moc (dane z $\text{Exp}(1)$)			Empiryczny α (dane z $N(0, 1)$)		
	KS	SW	D'A	KS	SW	D'A
2	0.242	0.946	0.792	0.048	0.053	0.059
3	0.180	0.822	0.654	0.049	0.050	0.055
5	0.121	0.581	0.470	0.049	0.046	0.058
7	0.096	0.459	0.379	0.050	0.054	0.058
10	0.093	0.339	0.300	0.051	0.050	0.055
15	0.078	0.239	0.223	0.053	0.050	0.055
20	0.065	0.193	0.180	0.052	0.049	0.057
30	0.061	0.139	0.144	0.053	0.049	0.054
50	0.061	0.102	0.106	0.052	0.052	0.056
70	0.057	0.091	0.096	0.049	0.051	0.059
100	0.055	0.077	0.081	0.049	0.049	0.057
200	0.050	0.065	0.071	0.048	0.050	0.061
500	0.051	0.055	0.063	0.052	0.051	0.057


Rysunek 4 przedstawia te same liczby w postaci wykresu. Empiryczne rozmiary testów stabilnie oscylują wokół poziomu 0,05 niezależnie od n , co świadczy o tym, że żaden z testów nie traci poprawności dla próbek o liczności $K = 50$.



Rysunek 4: Weryfikacja błędu I rodzaju: empiryczna frakcja odrzuceń H_0 dla danych pochodzących z $N(0, 1)$ w funkcji n . Wszystkie krzywe oscylują w pobliżu nominalnego $\alpha = 0,05$.

1.2.3 Estymacja skośności i kurtozy nadmiarowej $\bar{X}_n$

Dla pełnego zrozumienia, dlaczego test D'Agostino przestaje wykrywać odchylenia od normalności wraz ze wzrostem n , kluczowe są dwie wielkości, na których opiera się jego statystyka: skośność g_1 oraz kurtoza nadmiarowa g_2 . Rysunek 5 przedstawia ich estymaty empiryczne wraz z krzywymi teoretycznymi $2/\sqrt{n}$ i $6/n$ właściwymi dla średniej z rozkładu $\text{Exp}(1)$.



Rysunek 5: Estymacja skośności (panel lewy) i kurtozy nadmiarowej (panel prawy) średniej $\bar{X}_n$ z rozkładu $\text{Exp}(1)$. Punkty - wartości empiryczne (po 100 000 realizacji $\bar{X}_n$ dla każdego n); linie przerywane - teoretyczne $2/\sqrt{n}$ oraz $6/n$.

Lewy panel pokazuje skośność. Punkty empiryczne pokrywają się z krzywą $2/\sqrt{n}$ z dokładnością odpowiadającą szumowi Monte Carlo - dla $n = 2$ wartość empiryczna wynosi 1,40 przy teoretycznej 1,41, dla $n = 30$ jest to 0,37 wobec 0,37, a dla $n = 500$ empiryczna skośność spada do 0,09, w pełnej zgodzie z teorią. Prawy panel, w skali logarytmicznej na obu osiach, ilustruje analogiczne zachowanie kurtozy nadmiarowej: empiryczne wartości układają się wzdłuż linii prostej o nachyleniu odpowiadającym $1/n$. Dla największych n punkty zaczynają nieznacznie odbiegać od linii teoretycznej - jest to efekt rosnącego względnego błędu estymatora kurtozy, gdy szacowana wartość zbliża się do zera (przy $n = 500$ teoretyczna kurtoza nadmiarowa wynosi 0,012, więc nawet niewielka odchyłka empiryczna staje się widoczna w skali logarytmicznej).

Pełne wartości liczbowe zebrano w tabeli 2.

Tabela 2: Skośność i kurtoza nadmiarowa średniej $\bar{X}_n$ z rozkładu $\text{Exp}(1)$: empiryczne wartości z 100 000 realizacji dla każdego n i krzywe teoretyczne.

n	Skośność		Kurtoza nadmiarowa	
	empiryczna	teoretyczna $2/\sqrt{n}$	empiryczna	teoretyczna $6/n$
2	1.3993	1.4142	2.9220	3.0000
3	1.1525	1.1547	2.0117	2.0000
5	0.8986	0.8944	1.2356	1.2000
7	0.7531	0.7559	0.8661	0.8571
10	0.6184	0.6325	0.5663	0.6000
15	0.5170	0.5164	0.4103	0.4000
20	0.4407	0.4472	0.2767	0.3000
30	0.3710	0.3651	0.1966	0.2000
50	0.2755	0.2828	0.0792	0.1200
70	0.2506	0.2390	0.0876	0.0857
100	0.2004	0.2000	0.0777	0.0600
200	0.1456	0.1414	0.0204	0.0300
500	0.0875	0.0894	-0.0016	0.0120

1.3 Interpretacja wyników i wnioski

Wyniki symulacji prowadzą do kilku spójnych obserwacji, które łącznie odpowiadają na pytanie postawione w treści zadania.

Najwyższą moc w analizowanym przypadku wykazuje test Shapiro-Wilka. Jego przewaga jest widoczna w całym zakresie n i wynika z konstrukcji statystyki: porównanie kombinacji liniowej statystyk pozycyjnych z wariancją próby jest czułe zarówno na asymetrię, jak i na ciężkie ogony rozkładu, a niewielkie K (rzędu kilkudziesięciu) jest dla niego korzystne. Tuż za nim plasuje się test D’Agostino, który również daje wysoką moc dla małych n , lecz pozostaje konsekwentnie nieco słabszy od Shapiro-Wilka. Jego siła zależy bezpośrednio od skośności i kurtozy nadmiarowej $\bar{X}_n$: dla $n = 2$ teoretyczna skośność wynosi około 1,41, a kurtoza nadmiarowa 3, więc test wyraźnie identyfikuje obie nieregularności. Dla $n = 50$ obie wielkości maleją (teoretycznie do 0,28 oraz 0,12) na tyle blisko zera, że statystyka K^2 rzadko przekracza wartość krytyczną i moc testu zbliża się do α .

Test Kołmogorowa-Smirnowa wypada zdecydowanie najslabiej. Wynika to z natury jego statystyki: maksymalna różnica między dystrybuantą empiryczną a dystrybuantą referencyjną jest miarą globalną i zwykle nieczułą na lokalne odchylenia w ogonach, które najmocniej różnicują rozkład $\bar{X}_n$ od normalnego. Należy przy tym podkreślić, że porównanie nie jest w pełni jednorodne: test Kołmogorowa-Smirnowa badamy względem w pełni określonej hipotezy $N(\mu, \sigma^2/n)$ ze znanymi parametrami, podczas gdy testy Shapiro-Wilka i D’Agostino sprawdzają złożoną hipotezę normalności z parametrami szacowanymi z próby. Co więcej, wariant ze znanymi parametrami nie jest najkorzystniejszą postacią tego testu - skalibrowana odmiana Lillieforsa, estymująca parametry z próby, byłaby dla tego problemu wyraźnie mocniejsza, ponieważ całą czułość kieruje na kształt rozkładu, a nie na jego położenie i skalę. Nawet jednak ta silniejsza wersja pozostawałaby poniżej testów D’Agostino i Shapiro-Wilka, więc wniosek o najniższej skuteczności testu Kołmogorowa-Smirnowa jest odporny na wybór wariantu. Jego moc na poziomie 0,24 przy

$n = 2$ jest najgorszym wynikiem spośród wszystkich trzech metod, a wraz ze wzrostem n szybko maleje - od $n \geq 30$ przewyższa poziom istotności już tylko nieznacznie, by dla $n \approx 200$ praktycznie się z nim zrównać.

Estymacja skośności i kurtozy nadmiarowej bezpośrednio wyjaśnia kształt krzywej mocy testu D'Agostino. Tempo spadku tych wielkości (proporcjonalnie do $1/\sqrt{n}$ oraz $1/n$) odpowiada tempu zaniku mocy widocznemu na rysunku 2, co potwierdza, że test ten działa zgodnie z założeniami konstrukcyjnymi. Bardzo dobra zgodność wartości empirycznych z teorią dla rozkładu $\text{Exp}(1)$ stanowi również silne potwierdzenie poprawności symulacji oraz precyzji estymatorów momentów.

Z punktu widzenia zastosowań praktycznych można sformułować następujący wniosek. W przypadku testowania normalności średniej arytmetycznej zmiennych skośnych przy umiarkowanej liczności próby K (kilkadziesiąt obserwacji) najsensowniejszym wyborem jest test Shapiro-Wilka. Test D'Agostino stanowi rozsądną alternatywę, gdy chce się jednocześnie diagnozować, czy odchylenie od normalności wynika ze skośności, czy z grubości ogonów - wynik testu można wtedy uzupełnić bezpośrednią inspekcją wartości skośności i kurtozy. Testu Kołmogorowa-Smirnowa nie należy stosować jako podstawowego narzędzia do testowania normalności - jego moc jest znacząco niższa niż konkurencyjnych testów dedykowanych temu problemowi.

Wreszcie, niezależnie od użytego testu, wraz ze wzrostem n wszystkie krzywe mocy zbiegają do poziomu istotności $\alpha = 0,05$. Oznacza to, że dla wystarczająco dużej liczby uśrednianych zmiennych żaden ze stosowanych testów nie potrafi już wykryć odchylenia $\bar{X}_n$ od rozkładu normalnego - rozkład ten staje się praktycznie nieodróżnialny od normalnego, co stanowi tezę Centralnego Twierdzenia Granicznego.

2 Problem 2 - odbiornik znanego sygnału

2.1 Zadanie, założenia

Zadanie dotyczy projektowania algorytmu do wykrycia obecności tajnego kodu w szumie. Jego szczegóły są następujące:

- Jest ustalony tajny kod $s_i \in \{-1, 1\}$ o długości N , gdzie $i \in \{1, 2, \dots, N\}$
- Przesyłamy tajny kod ukryty w szumie gaussowskim.
- Szum $w_i \sim N(0, \sigma^2)$
- Sygnał x_i
- Cel: zaprojektować algorytm do wykrycia obecności tajnego kodu w sygnale
- Problem równoważny testowaniu hipotez:
 - $H_0 : x_i = w_i$, wtedy $x_i \sim \mathcal{N}(0, \sigma^2)$
 - $H_1 : x_i = As_i + w_i$, wtedy $x_i \sim \mathcal{N}(As_i, \sigma^2)$
- Parametry:
 - N — długość kodu i sygnału
 - σ^2 — wariancja szumu

- A — amplituda tajnego kodu
- x_i traktujemy jako próbę losową; statystykę testową stanowi logarytm ilorazu wiarygodności
- Kluczowe wielkości:
 - α — poziom istotności, czyli prawdopodobieństwo fałszywego alarmu (wykrywamy tajny kod, gdy nie jest przesyłany)
 - $1 - \beta$ — moc testu, czyli prawdopodobieństwo wykrycia tajnego kodu, gdy jest faktycznie przesyłany

2.2 Statystyka testowa

Dla uproszczenia obliczeń stosujemy logarytm ilorazu wiarygodności zamiast samego ilorazu wiarygodności:

$$T = \ln \left(\frac{L_{x_i|H_1}}{L_{x_i|H_0}} \right) = \ln(L_{x_i|H_1}) - \ln(L_{x_i|H_0}) = l_{x_i|H_1} - l_{x_i|H_0}$$

Składniki sumy:

$$l_{x_i|H_0} = \ln \left(\prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(\frac{-x_i^2}{2\sigma^2} \right) \right) = N \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \left(-\frac{1}{2\sigma^2} \right) \sum_{i=1}^N x_i^2$$

$$l_{x_i|H_1} = \ln \left(\prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(\frac{-(x_i - As_i)^2}{2\sigma^2} \right) \right) = N \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) + \left(-\frac{1}{2\sigma^2} \right) \sum_{i=1}^N (x_i - As_i)^2$$

Podstawiając do T (wykorzystując $s_i^2 = 1$):

$$T = \left(-\frac{1}{2\sigma^2} \right) \sum_{i=1}^N (x_i^2 - 2Ax_i s_i + A^2 s_i^2 - x_i^2) = \left(-\frac{1}{2\sigma^2} \right) \left(NA^2 - 2A \sum_{i=1}^N x_i s_i \right)$$

$$T = -\frac{NA^2}{2\sigma^2} + \frac{A}{\sigma^2} \sum_{i=1}^N x_i s_i$$

Duża wartość ($T \geq t_c$) świadczy na korzyść H_1 , natomiast mała wartość ($T < t_c$) na korzyść H_0 .

Taka statystyka testowa wychodzi z ilorazu wiarygodności, dodatkowo daje się intuicyjnie zinterpretować. Człon $\sum_{i=1}^N x_i s_i$ to iloczyn skalarny sygnału x i tajnego kodu s . Iloczyn skalarny jest miarą podobieństwa, więc (z dokładnością do czynników stałych) większe podobieństwo - większa wartość T - większe przekonanie o prawdziwości H_1 , że sygnał zawiera tajny kod.

2.3 Rozkład statystyki testowej

Statystyka testowa T ma postać

$$T = \frac{A}{\sigma^2} \sum_{i=1}^N x_i s_i - \frac{NA^2}{2\sigma^2} = aY + b, \quad \text{gdzie} \quad Y = \sum_{i=1}^N x_i s_i$$

Dla uproszczenia analizy najpierw rozpatrujemy rozkład Y .

2.3.1 Rozkład Y

Zmienna Y jest kombinacją liniową niezależnych zmiennych losowych x_i o rozkładzie normalnym, zatem sama ma rozkład normalny.

Rozkład Y pod H_0 Przy $H_0 : x_i = w_i \sim \mathcal{N}(0, \sigma^2)$ mamy:

$$Y|H_0 = \sum_{i=1}^N w_i s_i$$

$$\mathbb{E}[Y|H_0] = 0, \quad \mathbb{V}[Y|H_0] = N\sigma^2$$

$$Y|H_0 \sim \mathcal{N}(0, N\sigma^2)$$

Rozkład Y pod H_1 Przy $H_1 : x_i = As_i + w_i$ oraz $s_i \in \{-1, 1\} \Rightarrow s_i^2 = 1$:

$$Y|H_1 = \sum_{i=1}^N (As_i + w_i)s_i = AN + \sum_{i=1}^N s_i w_i$$

$$\mathbb{E}[Y|H_1] = AN, \quad \mathbb{V}[Y|H_1] = N\sigma^2$$

$$Y|H_1 \sim \mathcal{N}(AN, N\sigma^2)$$

2.3.2 Rozkład T

Na podstawie rozkładu Y oraz transformacji $T = aY + b$ otrzymujemy:

$$T|H_0 \sim \mathcal{N}\left(-\frac{A^2N}{2\sigma^2}, \frac{A^2N}{\sigma^2}\right)$$

$$T|H_1 \sim \mathcal{N}\left(\frac{A^2N}{2\sigma^2}, \frac{A^2N}{\sigma^2}\right)$$

2.4 Poziom istotności i wartość krytyczna

Przy ustalonym poziomie istotności α , wartość krytyczna t_c spełnia warunek:

$$P(T > t_c | H_0) = \alpha$$

co daje

$$t_c = F_{T|H_0}^{-1}(1 - \alpha) = -\frac{A^2N}{2\sigma^2} + \frac{A\sqrt{N}}{\sigma}\Phi^{-1}(1 - \alpha)$$


Uproszczona postać testu W porównaniu $T > t_c$ występują wspólne człony, więc postać testu można uprościć:

$$\begin{aligned}
T > t_c &\iff \frac{A}{\sigma^2} \sum_{i=1}^N x_i s_i - \frac{A^2 N}{2\sigma^2} > \frac{A\sqrt{N}}{\sigma} \Phi^{-1}(1 - \alpha) - \frac{A^2 N}{2\sigma^2} \\
&\iff \frac{A}{\sigma^2} \sum_{i=1}^N x_i s_i > \frac{A\sqrt{N}}{\sigma} \Phi^{-1}(1 - \alpha) \\
&\iff \sum_{i=1}^N x_i s_i > \sigma\sqrt{N} \cdot \Phi^{-1}(1 - \alpha)
\end{aligned}$$

2.5 Moc testu

Korzystając z wyprowadzonego rozkładu T i wzoru na t_c , można analitycznie wyrazić moc testu $1 - \beta$, czyli prawdopodobieństwo wykrycia tajnego kodu, gdy faktycznie jest przesyłany:


$$\begin{aligned}
1 - \beta &= P(T \geq t_c | H_1) = 1 - F_{T|H_1}(t_c) = 1 - \Phi\left(\frac{t_c - \frac{A^2 N}{2\sigma^2}}{\frac{A\sqrt{N}}{\sigma}}\right) \\
&= 1 - \Phi\left(\frac{-\frac{A^2 N}{2\sigma^2} + \frac{A\sqrt{N}}{\sigma} \Phi^{-1}(1 - \alpha) - \frac{A^2 N}{2\sigma^2}}{\frac{A\sqrt{N}}{\sigma}}\right) \\
1 - \beta &= 1 - \Phi\left(\Phi^{-1}(1 - \alpha) - \frac{A\sqrt{N}}{\sigma}\right)
\end{aligned}$$




Rysunek 6: Rozkład statystyki testowej dla parametrów, w których hipotezy są dobrze rozdzielne.

2.6 Symulacje


- Wykonane w notatniku Jupyter
- Weryfikuję poprawność wyprowadzeń symulując sygnały zawierające losowe szумы i wylosowane tajne kody
- Dla każdego przykładu obliczam wartość statystyki testowej i porównuję z wartością krytyczną
- Moc testu to stosunek liczby poprawnych wykryć tajnego kodu do liczby wszystkich przykładów
- Wykreślam krzywą mocy testu w zależności od stosunku $\frac{A^2 N}{\sigma^2}$
- Powtarzam dla różnych poziomów istotności α
- Jak widać na wykresach, wyniki są zgodne ze wzorem teoretycznym



Rysunek 7: Moc testu w zależności od SNR dla $\alpha = 0.01$.




Rysunek 8: Moc testu w zależności od SNR dla $\alpha = 0.001$.




Rysunek 9: Moc testu w zależności od SNR dla $\alpha = 0.0001$.

2.7 Moc testu przy słabym sygnale ($A \ll \sigma^2$)

Moc testu zależy od wartości $\frac{A\sqrt{N}}{\sigma}$. Zatem przy $A \ll \sigma^2$ możemy zwiększyć moc testu zwiększając N (długość tajnego kodu i całego sygnału).



Rysunek 10: Przypadek trudny: $A \ll \sigma^2$.



Rysunek 11: Przypadek łatwiejszy: $A \ll \sigma^2$ ale znacznie dłuższy sygnał.

2.8 Koncepcja systemu alarmowego

- Wymaga uzgodnienia tajnego kodu między nadawcą i odbiorcą sygnału, można wykorzystać np. protokół wymiany klucza Diffiego-Hellmana
- Założenia
 - sygnał ma być trudny do wykrycia przez obcych
 - prawdopodobieństwo fałszywego alarmu ma być niskie

Dla uproszczenia rozważań przyjmijmy, że odbiorca w stałych oknach czasowych analizuje sygnał (pakiet) $x_1, \dots, x_N$ (tzn. analizuje $x_1, \dots, x_N$ odebrane w chwili/oknie $t_1, t_2, \dots$).

α określa prawdopodobieństwo fałszywego alarmu dla jednego pakietu. Przy dobieraniu wartości tego parametru należy uwzględnić częstotliwość wysyłania pakietów (1000 dziennie, 1000000 dziennie?). W rzeczywistym zastosowaniu byłoby to zapewne powiązane z wielkością pakietu N . Przy stałej przepływności kanału, większe N oznacza mniejszą częstotliwość wysyłania pakietów.

Przez "trudny do wykrycia przez obcych" rozumiem niski stosunek A/σ^2 (tajny sygnał gdy jest przesyłany to zlewa się z szumem). Wtedy aby umożliwić poprawne działanie (niskie α , wysokie $1 - \beta$) musimy przyjąć odpowiednio duże N jak zilustrowano na wykresach powyżej.

Wartość $\frac{A^2 N}{\sigma^2}$ można interpretować jako stosunek sygnału do szumu (SNR).

2.9 Koncepcja systemu telekomunikacyjnego

Obecność lub nieobecność kodu możemy traktować jako przesłanie jednego bitu informacji (0 - brak kodu, 1 - obecność kodu).

W takiej sytuacji chcemy zminimalizować sumaryczną stopę błędów (bit error rate), czyli obie sytuacje (kod obecny / nieobecny) traktujemy symetrycznie. Rozkład statystyki testowej pod H_0 i H_1 jest symetryczny względem zera, najlepszym wyborem progu jest $t_c = 0$.