

Politechnika Warszawska
Wydział Elektroniki i Technik Informacyjnych

Statystyka w Analizie Danych

01.06.2026

Projekt 2

Testy zgodności rozkładu średniej z rozkładem normalnym
oraz detekcja słabego sygnału w szumie

Autorzy:

Mikołaj Garbowski, nr albumu XXXXXX
Bartłomiej Dmitruk, nr albumu 324911

Warszawa, 2026

Spis treści

1	Problem 1 - CTG, kontynuacja Projektu 1	2
1.1	Metoda rozwiązania problemu	2
1.2	Wyniki	3
1.2.1	Ilustracja zbieżności $\bar{X}_n$ do rozkładu normalnego	3
1.2.2	Moc testów normalności	4
1.2.3	Estymacja skośności i kurtozy nadmiarowej $\bar{X}_n$	8
1.3	Interpretacja wyników i wnioski	9
2	Problem 2 - odbiornik znanego sygnału	10
2.1	Metoda rozwiązania problemu	10
2.2	Wyniki	11
2.2.1	Rozkład statystyki testu i weryfikacja teorii	11
2.2.2	Wpływ amplitudy, długości sygnału i poziomu szumu	13
2.2.3	Wpływ poziomu istotności i uniwersalne skalowanie	15
2.2.4	Detekcja sygnału bardzo słabego $A \ll \sigma$	18
2.3	Interpretacja wyników i wnioski	19
2.4	Koncepcja systemu telekomunikacyjnego	20

1 Problem 1 - CTG, kontynuacja Projektu 1

1.1 Metoda rozwiązania problemu

Zadanie polega na ilościowym ujęciu zbieżności rozkładu średniej arytmetycznej $\bar{X}_n$ niezależnych zmiennych losowych do rozkładu normalnego, wynikającej z Centralnego Twierdzenia Granicznego. O ile w pierwszej części projektu zbieżność ta była pokazywana w sposób obrazowy (histogramy, estymatory jądrowe, dystrybuanty empiryczne, wykresy kwantyl-kwantyl), o tyle w tym problemie należy zbadać ją za pomocą statystycznych testów zgodności i porównać moce trzech klasycznych narzędzi: testu Kołmogorowa-Smirnowa, testu Shapiro-Wilka oraz testu D'Agostino. Wynikiem porównania ma być wskazanie, który test najskuteczniej wykrywa odchylenia rozkładu $\bar{X}_n$ od rozkładu normalnego w analizowanym przypadku. Uzupełnienie analizy stanowi estymacja skośności i kurtozy nadmiarowej $\bar{X}_n$ jako wielkości, na których wprost opiera się statystyka testu D'Agostino.

Wybór rozkładu bazowego padł na rozkład wykładniczy z parametrem $\lambda = 1$, czyli $X \sim \text{Exp}(1)$. Decyzja ta wynika z dwóch przesłanek. Po pierwsze, rozkład wykładniczy jest silnie skośny (skośność równa 2) i ma kurtozę nadmiarową 6, dzięki czemu odchylenie $\bar{X}_n$ od rozkładu normalnego dla małych n jest wyraźne, a jednocześnie zanika w znanym tempie. Po drugie, wszystkie istotne momenty są dane wzorami analitycznymi ($\mu = 1$, $\sigma^2 = 1$, $\text{Skew}(\bar{X}_n) = 2/\sqrt{n}$, $\text{ExcessKurt}(\bar{X}_n) = 6/n$), co pozwala bezpośrednio porównać estymaty empiryczne z teorią.

Strukturę eksperymentu opisują dwa różne parametry, których nie należy mylić. Liczba uśrednianych zmiennych n wyznacza próbkę, której średnia ma być testowana - jej rosnące wartości odpowiadają coraz lepszemu dopasowaniu $\bar{X}_n$ do rozkładu normalnego. Liczba średnich K , podawana na wejście pojedynczego testu, opisuje, ile niezależnych realizacji $\bar{X}_n$ test otrzymuje naraz; im większe K , tym silniejszy test (lepsza zdolność wykrycia odchylenia). Zgodnie z zaleceniem projektowym przyjęto $K = 50$ - umiarkowaną wartość rzędu kilkudziesięciu. Liczba uśrednianych zmiennych przyjmuje wartości $n \in \{2, 3, 5, 7, 10, 15, 20, 30, 50, 70, 100, 200, 500\}$, co pokrywa całą strefę przejścia od małych prób, gdzie odchylenie od normalności jest wyraźne, aż do prób, dla których żaden z testów nie potrafi już rozróżnić $\bar{X}_n$ od $N(\mu, \sigma^2/n)$.

Schemat pojedynczej symulacji wygląda następująco. Dla ustalonego n generowanych jest K niezależnych prób o liczności n z rozkładu $\text{Exp}(1)$ i z każdej obliczana jest średnia arytmetyczna. Otrzymany wektor K średnich stanowi wejście dla trzech testów normalności. Test Kołmogorowa-Smirnowa porównuje dystrybuantę empiryczną standaryzowanych średnich z dystrybuantą $N(0, 1)$ przy znanych parametrach μ oraz σ , co zapewnia poprawny rozmiar testu i pozwala uniknąć poprawki Lillieforsa. Test Shapiro-Wilka opiera się na statystyce porównującej kombinację liniową statystyk pozycyjnych z wariancją próby i jest powszechnie uznawany za jeden z najmocniejszych testów normalności w niewielkich próbach. Test D'Agostino-Pearsona (statystyka K^2) łączy dwa składniki: jeden zależy od skośności, drugi od kurtozy, dzięki czemu test wprost wykrywa najczęstsze formy odejścia od normalności. Całość powtórzono 10 000 razy dla każdej wartości n , a frakcję odrzuceń hipotezy zerowej przy poziomie istotności $\alpha = 0,05$ przyjęto jako estymator mocy.

Aby zweryfikować poprawność implementacji oraz upewnić się, że wszystkie trzy testy utrzymują nominalny poziom istotności, równolegle przeprowadzono symulację kontrolną. W tej wersji K średnich generowano bezpośrednio z rozkładu normalnego $N(0, 1)$ - hipoteza zerowa jest wtedy prawdziwa, a frakcja odrzuceń powinna być bliska α . Odchylenia od 0,05 większe niż wynikające z błędu Monte Carlo wskazywałyby na problem z

implementacją lub niewłaściwą standaryzacją w teście Kołmogorowa-Smirnowa.

Estymację skośności i kurtozy nadmiarowej $\bar{X}_n$ przeprowadzono osobno, używając 100 000 niezależnych realizacji średniej dla każdej wartości n . Empiryczne wartości momentów porównano z formułami teoretycznymi $\text{Skew}(\bar{X}_n) = 2/\sqrt{n}$ i $\text{ExcessKurt}(\bar{X}_n) = 6/n$, właściwymi dla bazowego rozkładu $\text{Exp}(1)$. Spadek skośności jak $1/\sqrt{n}$ oraz kurtozy jak $1/n$ odpowiada za stopniowy zanik mocy testu D’Agostino, którego statystyka właśnie z tych dwóch wielkości jest zbudowana.


Symulacje zaimplementowano w języku Python z wykorzystaniem bibliotek `numpy` oraz `scipy.stats`; testy wywołują funkcje `kstest`, `shapiro` i `normaltest`. Wszystkie generatory liczb pseudolosowych zainicjalizowano oddzielnymi ziarnami pochodnymi od stałej `SEED = 42`, dzięki czemu wyniki są w pełni powtarzalne.

1.2 Wyniki

1.2.1 Ilustracja zbieżności $\bar{X}_n$ do rozkładu normalnego

Punktem wyjścia analizy jest wizualne potwierdzenie, że standaryzowana średnia $Z_n = (\bar{X}_n - \mu)/(\sigma/\sqrt{n})$ rzeczywiście zbiega do $N(0, 1)$ wraz ze wzrostem n . Rysunek 1 przedstawia w górnym rzędzie histogramy gęstości Z_n uzyskane ze 100 000 niezależnych realizacji dla czterech wybranych wartości $n \in \{2, 10, 50, 200\}$, a w dolnym - odpowiadające im wykresy kwantyl-kwantyl względem rozkładu $N(0, 1)$. Dla $n = 2$ histogram zachowuje wyraźną prawostronną skośność dziedziczną z rozkładu wykładniczego: wartość modalna leży po lewej stronie zera, prawy ogon jest znacznie wydłużony, a wykres kwantyl-kwantyl odchyła się od prostej w obu krańcach, najmocniej w prawym ogonie. Dla $n = 10$ asymetria histogramu wyraźnie się zmniejsza, a wykres kwantyl-kwantyl niemal pokrywa się z prostą w centralnej części, odchylenia pozostają jednak widoczne w prawym ogonie. Przy $n = 50$ histogram jest praktycznie symetryczny i bardzo dobrze odpowiada krzywej gęstości $N(0, 1)$, a wykres kwantyl-kwantyl tworzy linię praktycznie nieodróżnialną od idealnej diagonal. Dla $n = 200$ dopasowanie jest tak dobre, że żadnym z dwóch sposobów nie sposób gołym okiem stwierdzić odejścia od normalności - i właśnie tu pojawia się potrzeba zastosowania testów statystycznych, które jako jedyne dają obiektywną, ilościową odpowiedź na pytanie, czy odchylenie jest jeszcze wykrywalne.


Zbieżność rozkładu $\bar{X}_n$ do $N(0,1)$ dla rozkładu bazowego Exp(1)
Liczba prób na n : 100 000



Rysunek 1: Zbieżność standaryzowanej średniej $Z_n = (\bar{X}_n - \mu)/(\sigma/\sqrt{n})$ z rozkładu bazowego Exp(1) do rozkładu $N(0, 1)$. Górny rząd: histogramy gęstości na tle teoretycznej krzywej $N(0, 1)$. Dolny rząd: wykresy kwantyl-kwantyl względem rozkładu $N(0, 1)$.

1.2.2 Moc testów normalności


Centralny wynik pracy stanowi porównanie mocy trzech testów. Rysunek 2 pokazuje empiryczną frakcję odrzuceń hipotezy zerowej w funkcji liczby uśrednianych zmiennych n , przy stałym $K = 50$ i $\alpha = 0,05$. Wszystkie trzy krzywe są monotonicznie malejące - wraz ze wzrostem n rozkład $\bar{X}_n$ coraz lepiej naśladuje rozkład normalny, więc testom jest coraz trudniej wykryć odchylenie od $N(\mu, \sigma^2/n)$.



Rysunek 2: Moc testów normalności (frakcja odrzuceń H_0) dla średniej $\bar{X}_n$ z rozkładu Exp(1), $K = 50$, $\alpha = 0,05$, 10 000 symulacji.

Już z tego rysunku widać wyraźną hierarchię testów. Test Shapiro-Wilka odrzuca hipotezę zerową przy $n = 2$ w niemal 95% przypadków, podczas gdy test D'Agostino osiąga w tej samej sytuacji moc na poziomie 79%, a test Kołmogorowa-Smirnowa jedynie nieco ponad 24%. Hierarchia ta utrzymuje się we wszystkich badanych wartościach n , choć przewaga testu Shapiro-Wilka nad D'Agostino jest stała i niewielka, natomiast przewaga obu nad testem Kołmogorowa-Smirnowa jest wielokrotna. Dla $n = 50$, czyli przypadku $K = n$, moce testów Shapiro-Wilka i D'Agostino spadają do około 10%, a test Kołmogorowa-Smirnowa rejestruje już wartości w okolicach poziomu istotności - dla próby tej długości żaden z testów praktycznie nie odróżnia $\bar{X}_n$ od rozkładu normalnego.

Bliższy widok strefy przejściowej daje rysunek 3, na którym dodano linię referencyjną na poziomie mocy 0,5. Pozwala on odczytać, dla jakiej wartości n dany test zachowuje co najmniej połowiczną zdolność wykrycia odchylenia. Test Shapiro-Wilka utrzymuje moc powyżej 0,5 do około $n \approx 7$, test D'Agostino nieznacznie krócej - do mniej więcej $n \approx 5$, natomiast moc testu Kołmogorowa-Smirnowa nigdy w badanym zakresie tej granicy nie przekracza i już przy $n = 2$ pozostaje na poziomie ok. 0,24.




Rysunek 3: Strefa przejścia mocy testów normalności w pełnym zakresie pionowym z linią referencyjną na poziomie mocy 0,5, ułatwiającą porównanie tempa zaniku mocy między testami.

Pełne wartości liczbowe mocy testów zebrano w tabeli 1. W tej samej tabeli umieszczono również wyniki kontroli błędu I rodzaju - frakcję odrzuceń przy danych pochodzących z rozkładu $N(0, 1)$, kiedy hipoteza zerowa jest prawdziwa. Wartości te powinny być bliskie nominalnemu poziomowi istotności $\alpha = 0,05$, co rzeczywiście potwierdzają wyniki. Testy Kołmogorowa-Smirnowa i Shapiro-Wilka utrzymują empiryczny rozmiar praktycznie identyczny z nominalnym (różnice mieszczą się w zakresie szumu Monte Carlo), test D'Agostino nieznacznie odrzuca częściej (wartości w przedziale ok. 0,055-0,061). Pełna zgodność z α stanowi potwierdzenie, że standaryzacja w teście Kołmogorowa-Smirnowa oraz cała procedura symulacyjna są zaimplementowane poprawnie, a różnice w mocach widoczne na rysunku 2 wynikają faktycznie z odmiennej charakterystyki samych testów, nie z błędu metodologicznego.

Tabela 1: Moc testów normalności dla danych $\bar{X}_n$ z $\text{Exp}(1)$ oraz empiryczny rozmiar testów dla danych z $N(0, 1)$. $K = 50$, $\alpha = 0,05$, 10 000 symulacji.

n	Moc (dane z $\text{Exp}(1)$)			Empiryczny α (dane z $N(0, 1)$)		
	KS	SW	D'A	KS	SW	D'A
2	0.242	0.946	0.792	0.048	0.053	0.059
3	0.180	0.822	0.654	0.049	0.050	0.055
5	0.121	0.581	0.470	0.049	0.046	0.058
7	0.096	0.459	0.379	0.050	0.054	0.058
10	0.093	0.339	0.300	0.051	0.050	0.055
15	0.078	0.239	0.223	0.053	0.050	0.055
20	0.065	0.193	0.180	0.052	0.049	0.057
30	0.061	0.139	0.144	0.053	0.049	0.054
50	0.061	0.102	0.106	0.052	0.052	0.056
70	0.057	0.091	0.096	0.049	0.051	0.059
100	0.055	0.077	0.081	0.049	0.049	0.057
200	0.050	0.065	0.071	0.048	0.050	0.061
500	0.051	0.055	0.063	0.052	0.051	0.057


Rysunek 4 przedstawia te same liczby w postaci wykresu. Empiryczne rozmiary testów stabilnie oscylują wokół poziomu 0,05 niezależnie od n , co świadczy o tym, że żaden z testów nie traci poprawności dla próbek o liczności $K = 50$.



Rysunek 4: Weryfikacja błędu I rodzaju: empiryczna frakcja odrzuceń H_0 dla danych pochodzących z $N(0, 1)$ w funkcji n . Wszystkie krzywe oscylują w pobliżu nominalnego $\alpha = 0,05$.

1.2.3 Estymacja skośności i kurtozy nadmiarowej $\bar{X}_n$

Dla pełnego zrozumienia, dlaczego test D'Agostino przestaje wykrywać odchylenia od normalności wraz ze wzrostem n , kluczowe są dwie wielkości, na których opiera się jego statystyka: skośność g_1 oraz kurtoza nadmiarowa g_2 . Rysunek 5 przedstawia ich estymaty empiryczne wraz z krzywymi teoretycznymi $2/\sqrt{n}$ i $6/n$ właściwymi dla średniej z rozkładu $\text{Exp}(1)$.



Rysunek 5: Estymacja skośności (panel lewy) i kurtozy nadmiarowej (panel prawy) średniej $\bar{X}_n$ z rozkładu $\text{Exp}(1)$. Punkty - wartości empiryczne (po 100 000 realizacji $\bar{X}_n$ dla każdego n); linie przerywane - teoretyczne $2/\sqrt{n}$ oraz $6/n$.

Lewy panel pokazuje skośność. Punkty empiryczne pokrywają się z krzywą $2/\sqrt{n}$ z dokładnością odpowiadającą szumowi Monte Carlo - dla $n = 2$ wartość empiryczna wynosi 1,40 przy teoretycznej 1,41, dla $n = 30$ jest to 0,37 wobec 0,37, a dla $n = 500$ empiryczna skośność spada do 0,09, w pełnej zgodzie z teorią. Prawy panel, w skali logarytmicznej na obu osiach, ilustruje analogiczne zachowanie kurtozy nadmiarowej: empiryczne wartości układają się wzdłuż linii prostej o nachyleniu odpowiadającym $1/n$. Dla największych n punkty zaczynają nieznacznie odbiegać od linii teoretycznej - jest to efekt rosnącego względnego błędu estymatora kurtozy, gdy szacowana wartość zbliża się do zera (przy $n = 500$ teoretyczna kurtoza nadmiarowa wynosi 0,012, więc nawet niewielka odchyłka empiryczna staje się widoczna w skali logarytmicznej).

Pełne wartości liczbowe zebrano w tabeli 2.

Tabela 2: Skośność i kurtoza nadmiarowa średniej $\bar{X}_n$ z rozkładu $\text{Exp}(1)$: empiryczne wartości z 100 000 realizacji dla każdego n i krzywe teoretyczne.

n	Skośność		Kurtoza nadmiarowa	
	empiryczna	teoretyczna $2/\sqrt{n}$	empiryczna	teoretyczna $6/n$
2	1.3993	1.4142	2.9220	3.0000
3	1.1525	1.1547	2.0117	2.0000
5	0.8986	0.8944	1.2356	1.2000
7	0.7531	0.7559	0.8661	0.8571
10	0.6184	0.6325	0.5663	0.6000
15	0.5170	0.5164	0.4103	0.4000
20	0.4407	0.4472	0.2767	0.3000
30	0.3710	0.3651	0.1966	0.2000
50	0.2755	0.2828	0.0792	0.1200
70	0.2506	0.2390	0.0876	0.0857
100	0.2004	0.2000	0.0777	0.0600
200	0.1456	0.1414	0.0204	0.0300
500	0.0875	0.0894	-0.0016	0.0120

1.3 Interpretacja wyników i wnioski

Wyniki symulacji prowadzą do kilku spójnych obserwacji, które łącznie odpowiadają na pytanie postawione w treści zadania.

Najwyższą moc w analizowanym przypadku wykazuje test Shapiro-Wilka. Jego przewaga jest widoczna w całym zakresie n i wynika z konstrukcji statystyki: porównanie kombinacji liniowej statystyk pozycyjnych z wariancją próby jest czułe zarówno na asymetrię, jak i na ciężkie ogony rozkładu, a niewielkie K (rzędu kilkudziesięciu) jest dla niego korzystne. Tuż za nim plasuje się test D’Agostino, który również daje wysoką moc dla małych n , lecz pozostaje konsekwentnie nieco słabszy od Shapiro-Wilka. Jego siła zależy bezpośrednio od skośności i kurtozy nadmiarowej $\bar{X}_n$: dla $n = 2$ skośność wynosi około 1,41, a kurtoza 3, więc test wyraźnie identyfikuje obie nieregularności. Dla $n = 50$ skośność spada do 0,28, a kurtoza do 0,12 - wartości te są już na tyle blisko zera, że statystyka K^2 rzadko przekracza wartość krytyczną i moc testu zbliża się do α .

Test Kołmogorowa-Smirnowa wypada zdecydowanie najslabiej. Wynika to z natury jego statystyki: maksymalna różnica między dystrybuantą empiryczną a dystrybuantą referencyjną jest miarą globalną i zwykle nieczułą na lokalne odchylenia w ogonach, które najmocniej różnicują rozkład $\bar{X}_n$ od normalnego. Test ten ma dodatkowo strukturalną wadę dla problemu testowania normalności - dla typowych zastosowań wymaga znajomości parametrów rozkładu albo specjalnej poprawki Lillieforsa; w niniejszej pracy zastosowano standaryzację z parametrami teoretycznymi μ i σ , co eliminuje konserwatyzm wynikający z estymacji parametrów z próby, lecz nie zmienia zasadniczo charakterystyki testu. Jego moc na poziomie 0,24 przy $n = 2$ jest najgorszym wynikiem spośród wszystkich trzech metod, a dla $n \geq 30$ test ten działa praktycznie jak losowe odrzucenie z prawdopodobieństwem α .

Estymacja skośności i kurtozy nadmiarowej bezpośrednio wyjaśnia kształt krzywej mocy testu D’Agostino. Tempo spadku tych wielkości (proporcjonalnie do $1/\sqrt{n}$ oraz $1/n$) odpowiada tempu zaniku mocy widocznemu na rysunku 2, co potwierdza, że test ten działa

zgodnie z założeniami konstrukcyjnymi. Bardzo dobra zgodność wartości empirycznych z teorią dla rozkładu $\text{Exp}(1)$ stanowi również silne potwierdzenie poprawności symulacji oraz precyzji estymatorów momentów.

Z punktu widzenia zastosowań praktycznych można sformułować następujący wniosek. W przypadku testowania normalności średniej arytmetycznej zmiennych skośnych przy umiarkowanej liczności próby K (kilkadziesiąt obserwacji) najsensowniejszym wyborem jest test Shapiro-Wilka. Test D’Agostino stanowi rozsądną alternatywę, gdy chce się jednocześnie diagnozować, czy odchylenie od normalności wynika ze skośności, czy z grubości ogonów - wynik testu można wtedy uzupełnić bezpośrednią inspekcją wartości skośności i kurtozy. Testu Kołmogorowa-Smirnowa nie należy stosować jako podstawowego narzędzia do testowania normalności - jego moc jest znacząco niższa niż konkurencyjnych testów dedykowanych temu problemowi.

Wreszcie, niezależnie od użytego testu, wraz ze wzrostem n wszystkie krzywe mocy zbiegają do poziomu istotności $\alpha = 0,05$. Oznacza to, że dla wystarczająco dużej liczby uśrednianych zmiennych żaden ze stosowanych testów nie potrafi już wykryć odchylenia $\bar{X}_n$ od rozkładu normalnego - rozkład ten staje się praktycznie nieodróżnialny od normalnego, co stanowi tezę Centralnego Twierdzenia Granicznego.

2 Problem 2 - odbiornik znanego sygnału

2.1 Metoda rozwiązania problemu

Zadanie polega na zaprojektowaniu algorytmu detekcji, który w odebranych sygnale $x(i)$, $i = 1, \dots, N$ rozpoznaje obecność ukrytego, ustalonego z góry kodu pseudosumowego $s(i) \in \{-1, +1\}$ zatopionego w białym szumie gaussowskim $w(i) \sim \mathcal{N}(0, \sigma^2)$. Pomijając całą warstwę radiową (częstotliwość nośna, dobór anten, układy RF, synchronizacja) oraz przetwarzanie sygnału do postaci cyfrowej, ograniczamy się do dyskretnego problemu testowania dwóch prostych hipotez:

$$H_0: x(i) = w(i), \quad (1)$$

$$H_1: x(i) = A s(i) + w(i), \quad (2)$$

gdzie A jest nieznaną, dodatnią amplitudą sygnału. Poziom istotności testu odpowiada prawdopodobieństwu fałszywego alarmu i powinien być bardzo niski - w analizie rozważano wartości $\alpha \in \{10^{-2}, 10^{-3}, 10^{-4}, 10^{-6}\}$.

Optymalny test wynika bezpośrednio z lematu Neymana-Pearsona. Próbkki $x(i)$ nie mają identycznego rozkładu, lecz są niezależne, a ich łączna funkcja wiarygodności pod każdą z hipotez ma postać:

$$L_0(\mathbf{x}) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x(i)^2}{2\sigma^2}\right), \quad (3)$$

$$L_1(\mathbf{x}; A) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x(i) - A s(i))^2}{2\sigma^2}\right). \quad (4)$$

Iloraz wiarygodności po skróceniu wspólnych czynników i wykorzystaniu tożsamości $\sum_i s(i)^2 = N$ daje:

$$\log \frac{L_1}{L_0} = \frac{A}{\sigma^2} \sum_{i=1}^N s(i)x(i) - \frac{A^2 N}{2\sigma^2}. \quad (5)$$

Drugi człon nie zależy od danych, więc po zastosowaniu progowania na ilorazie wiarygodności decyzja sprowadza się do porównania pojedynczej statystyki

$$T = \sum_{i=1}^N s(i) x(i) \quad (6)$$

z progiem τ . Statystyka T jest zatem statystyką dostateczną dla problemu detekcji, a dla każdego $A > 0$ uzyskany test jest jednostajnie najmocniejszy w klasie testów o ustalonym poziomie istotności. W praktyce statystyka ta odpowiada operacji korelacji sygnału odebranego ze znanym kodem, czyli klasycznemu filtrowi dopasowanemu (matched filter).

Rozkład statystyki testowej jest pod obiema hipotezami gaussowski, ponieważ T jest kombinacją liniową zmiennych normalnych. Bezpośrednie obliczenie wartości oczekiwanej i wariancji daje:

$$T \mid H_0 \sim \mathcal{N}(0, \sigma^2 N), \quad (7)$$

$$T \mid H_1 \sim \mathcal{N}(AN, \sigma^2 N). \quad (8)$$

Próg dobiera się tak, aby prawdopodobieństwo fałszywego alarmu wynosiło dokładnie α :

$$\tau = z_{1-\alpha} \sigma \sqrt{N}, \quad (9)$$

gdzie $z_{1-\alpha}$ to kwantyl rzędu $1 - \alpha$ rozkładu $\mathcal{N}(0, 1)$. Moc testu, czyli prawdopodobieństwo poprawnej detekcji, wyraża się wzorem:

$$P_D = \Pr(T > \tau \mid H_1) = 1 - \Phi\left(z_{1-\alpha} - \frac{A\sqrt{N}}{\sigma}\right) = \Phi(d - z_{1-\alpha}), \quad (10)$$

gdzie Φ oznacza dystrybuantę rozkładu standardowego normalnego, a wielkość

$$d = \frac{A\sqrt{N}}{\sigma} \quad (11)$$

nazywana będzie dalej *efektywnym stosunkiem sygnału do szumu*. To kluczowy parametr układu - moc detekcji zależy od A , σ i N wyłącznie poprzez ich kombinację d . Wynika z tego natychmiast efekt zwany *processing gain*: dwukrotne wydłużenie sygnału kompensuje obniżenie amplitudy o czynnik $\sqrt{2}$ albo wzrost odchylenia standardowego szumu o ten sam czynnik. Inaczej mówiąc, można wykryć dowolnie słaby sygnał, jeśli tylko dostatecznie długo można obserwować jego znaną strukturę.


Symulacje Monte Carlo zrealizowano w języku Python z wykorzystaniem bibliotek `numpy` oraz `scipy.stats`. Dla każdego zestawu parametrów (N, A, σ, α) wylosowano kod s ze stałym ziarnem generatora (rozłożenia ± 1 z równym prawdopodobieństwem), a następnie wygenerowano po 50 000 niezależnych realizacji szumu pod obiema hipotezami. Empiryczne wartości prawdopodobieństw P_D i P_{FA} obliczono jako frakcję przekroczeń progu. Wszystkie generatory liczb pseudolosowych zainicjalizowano zmiennymi pochodnymi od stałej $SEED = 42$, co zapewnia powtarzalność wyników.

2.2 Wyniki

2.2.1 Rozkład statystyki testu i weryfikacja teorii

Punktem wyjścia analizy jest sprawdzenie, czy rozkład statystyki testowej T pod obiema hipotezami rzeczywiście pokrywa się z formułami teoretycznymi. Rysunek 6 przedstawia

histogramy gęstości T uzyskane z 200 000 realizacji dla wybranego zestawu parametrów ($N = 256$, $A = 0,3$, $\sigma = 1$). Pod H_0 histogram jest symetryczny wokół zera o rozrzucie $\sigma\sqrt{N} \approx 16$, pod H_1 jego środek przesuwa się o $AN = 76,8$, lecz rozrzut pozostaje identyczny. Naniesione krzywe teoretyczne $\mathcal{N}(0, \sigma^2 N)$ oraz $\mathcal{N}(AN, \sigma^2 N)$ pokrywają histogramy z dokładnością nieodróżnialną gołym okiem. Czerwona pionowa linia oznacza próg τ dla $\alpha = 10^{-3}$, który oddziela praktycznie cały rozkład pod H_0 od większości masy rozkładu pod H_1 , ilustrując mechanizm detekcji.



Rysunek 6: Rozkład statystyki testu $T = \sum_i s(i)x(i)$ pod hipotezami H_0 i H_1 wraz z teoretycznymi krzywymi gęstości oraz progiem decyzyjnym przy $\alpha = 10^{-3}$.

Tabela 3 zestawia teoretyczne i empiryczne wartości mocy detekcji oraz empiryczny rozmiar testu dla siedmiu reprezentatywnych konfiguracji (N, A, α) . We wszystkich przypadkach wartości empiryczne odbiegają od teoretycznych o nie więcej niż dwie cyfry znaczące, co w pełni mieści się w błędzie Monte Carlo dla 50 000 symulacji. Podobnie empiryczne prawdopodobieństwo fałszywego alarmu pozostaje praktycznie identyczne z nominalnym α , co potwierdza poprawność wyboru progu.


Tabela 3: Weryfikacja teoretycznych wzorów na moc detekcji i poziom fałszywego alarmu - empiryczne wartości z 50 000 symulacji Monte Carlo dla wybranych konfiguracji parametrów ($\sigma = 1$).

N	A	α	P_D teoria	P_D empir.	P_{FA} empir.
256	0.10	1e-02	0.2338	0.2344	0.0094
256	0.20	1e-02	0.8088	0.8077	0.0103
256	0.30	1e-03	0.9563	0.9576	0.0010
1024	0.05	1e-03	0.0681	0.0669	0.0011
1024	0.10	1e-03	0.5437	0.5448	0.0013
4096	0.03	1e-03	0.1210	0.1202	0.0010
4096	0.05	1e-02	0.8088	0.8092	0.0104

2.2.2 Wpływ amplitudy, długości sygnału i poziomu szumu


Wzór (10) przewiduje, że moc testu zależy od trzech parametrów A , N , σ jedynie poprzez efektywny stosunek $d = A\sqrt{N}/\sigma$. Aby zilustrować rolę każdego z nich osobno, kolejne trzy rysunki pokazują przekroje tej zależności, w których jeden parametr jest zmieniany, a pozostałe pozostają stałe.

Rysunek 7 przedstawia moc detekcji w funkcji amplitudy A przy ustalonym $\sigma = 1$ i $\alpha = 10^{-3}$, dla pięciu wartości $N \in \{16, 64, 256, 1024, 4096\}$. Wszystkie krzywe mają charakterystyczny kształt sigmoidalny, gwałtownie przechodząc od $P_D \approx \alpha$ dla małych A do $P_D \approx 1$ dla dużych. Punkt przegięcia każdej krzywej (mocy 0,5) przypada na $A \approx z_{1-\alpha}\sigma/\sqrt{N}$, czyli skaluje się jak $1/\sqrt{N}$. Praktyczna konsekwencja jest taka, że czterokrotne wydłużenie sygnału obniża wymaganą amplitudę detekcji dwukrotnie.




Rysunek 7: Moc detekcji w funkcji amplitudy sygnału A dla różnych długości N przy stałym $\sigma = 1$, $\alpha = 10^{-3}$.

Rysunek 8 pokazuje to samo zjawisko z innej perspektywy - moc w funkcji długości sygnału N przy ustalonych wartościach stosunku $A/\sigma \in \{0,05; 0,1; 0,2; 0,5; 1,0\}$. Krzywe są symetrycznie przesunięte względem siebie w skali logarytmicznej osi N : aby uzyskać tę samą moc detekcji, dwukrotne zmniejszenie amplitudy wymaga czterokrotnego wydłużenia sygnału. Dla $A = 0,05\sigma$ osiągnięcie mocy 0,9 wymaga N rzędu 5000 próbek, podczas gdy dla $A = \sigma$ wystarczy zaledwie kilkanaście próbek.



Rysunek 8: Moc detekcji w funkcji długości sygnału N dla różnych stosunków A/σ przy $\alpha = 10^{-3}$.


Trzecim parametrem analizowanym osobno jest odchylenie standardowe szumu σ . Rysunek 9 pokazuje moc detekcji jako funkcję σ dla pięciu kombinacji (A, N) . Zgodnie z formułą (10) każda krzywa monotonicznie maleje wraz ze wzrostem poziomu szumu, dążąc do wartości α dla bardzo dużego σ . Kombinacje, które dają identyczny iloczyn $A\sqrt{N}$, prowadzą do krzywych o tym samym kształcie, jedynie przesuniętych wzdłuż osi σ . Konfiguracje $A = 0,3, N = 1024$ oraz $A = 0,1, N = 4096$ na rysunku wyglądają prawie identycznie, gdyż obie odpowiadają tej samej wartości $A\sqrt{N} \approx 9,6$. Dla pierwszej z nich detektor utrzymuje moc 0,9 aż do $\sigma \approx 2,5$, podczas gdy konfiguracja $A = 0,3, N = 256$ traci tę zdolność już dla $\sigma \approx 1,25$.



Rysunek 9: Moc detekcji w funkcji odchylenia standardowego szumu σ dla różnych kombinacji (A, N) przy $\alpha = 10^{-3}$.


2.2.3 Wpływ poziomu istotności i uniwersalne skalowanie

Wymóg bardzo niskiego prawdopodobieństwa fałszywego alarmu, podany wprost w treści zadania, znacząco zmienia wymagania na sygnał. Rysunek 10 pokazuje moc detekcji w funkcji α przy ustalonym $N = 256$ dla czterech wartości amplitudy. Dla każdej z nich obniżenie α o cztery rzędy wielkości (z 10^{-2} do 10^{-6}) wymaga proporcjonalnie większego marginesu w efektywnym SNR. Przy $A = 0,5$ ($d = 8$) detektor utrzymuje moc bliską 1 nawet dla $\alpha = 10^{-8}$, natomiast przy $A = 0,1$ ($d = 1,6$) już dla $\alpha = 10^{-3}$ moc spada poniżej 30%.




Rysunek 10: Moc detekcji w funkcji prawdopodobieństwa fałszywego alarmu α dla różnych amplitud sygnału przy $N = 256, \sigma = 1$.

Trzy poprzednie rysunki można uznać za różne projekcje jednej fundamentalnej zależności. Rysunek 11 przedstawia tę zależność wprost - moc detekcji jako funkcję efektywnego SNR $d = A\sqrt{N}/\sigma$ dla czterech poziomów istotności. Każda krzywa jest przesuniętą kopią dystrybucji rozkładu standardowego normalnego $\Phi(d - z_{1-\alpha})$, a wszystkie kombinacje (A, N, σ) dające tę samą wartość d leżą dokładnie na tej krzywej. Praktyczne progi detekcji są łatwo odczytywalne z wykresu - osiągnięcie mocy 0,9 wymaga $d \approx 4,1$ dla $\alpha = 10^{-3}$ oraz $d \approx 6,0$ dla $\alpha = 10^{-6}$.



Rysunek 11: Uniwersalna krzywa mocy detekcji jako funkcja efektywnego stosunku sygnału do szumu $d = A\sqrt{N}/\sigma$ dla różnych poziomów istotności.


Uzupełnieniem analizy są krzywe ROC (rysunek 12), które dla pięciu wartości efektywnego SNR $d \in \{0,5; 1; 2; 3; 4\}$ pokazują pełen zakres możliwych kompromisów między prawdopodobieństwem detekcji a prawdopodobieństwem fałszywego alarmu. Dla $d = 0,5$ detektor pracuje niewiele lepiej od losowego, natomiast dla $d = 4$ krzywa jest tak blisko lewego górnego rogu wykresu, że przy $P_{FA} = 10^{-3}$ daje już $P_D > 0,97$, a przy $P_{FA} = 10^{-6}$ wciąż przekracza 0,75.



Rysunek 12: Krzywe ROC dla pięciu wartości efektywnego stosunku sygnału do szumu $d = A\sqrt{N}/\sigma$.

2.2.4 Detekcja sygnału bardzo słabego $A \ll \sigma$

Najbardziej praktyczny aspekt tego zadania - detekcja sygnału o amplitudzie znacznie mniejszej od poziomu szumu - wynika bezpośrednio z formuły (11). Jeśli ustalić docelową moc detekcji, to wymagana długość sygnału skaluje się jak $N \propto (\sigma/A)^2$. Rysunek 13 pokazuje krzywe mocy w funkcji N dla czterech wartości amplitudy słabego sygnału w przedziale od $A = 0,01\sigma$ do $A = 0,3\sigma$. Liczby w legendzie podają długość sygnału potrzebną do osiągnięcia mocy 0,5 przy $\alpha = 10^{-3}$ - przy $A = 0,3\sigma$ wystarczy $N \approx 107$, przy $A = 0,1\sigma$ trzeba $N \approx 955$, przy $A = 0,03\sigma$ już ponad dziesięć tysięcy próbek, a przy $A = 0,01\sigma$ blisko sto tysięcy. Kwadratowe skalowanie tej liczby z odwrotnością stosunku A/σ jest dobrze widoczne na osi logarytmicznej jako stała odległość między krzywymi.



Rysunek 13: Detekcja sygnału słabego $A \ll \sigma$ - moc w funkcji długości sygnału N dla czterech amplitud w zakresie $0,01\sigma$ do $0,3\sigma$ przy $\alpha = 10^{-3}$.

Z punktu widzenia projektu systemu detekcji oznacza to, że nawet amplituda dwóch rzędów wielkości mniejsza od odchylenia szumu jest fundamentalnie wykrywalna - cena pozostaje jedynie w postaci czasu obserwacji, który rośnie kwadratowo wraz ze spadkiem amplitudy.

2.3 Interpretacja wyników i wnioski

Wszystkie uzyskane wyniki są wewnętrznie spójne i bezpośrednio wynikają z jednego centralnego wzoru (10). Ich łączna interpretacja pozwala sformułować kilka praktycznych obserwacji.

Po pierwsze, optymalny detektor sygnału o znanej strukturze polega na jego skorelowaniu z odebranyym sygnałem - jest to bezpośrednia konsekwencja lematu Neymana-Pearsona, a nie heurystyka. Statystyka $T = \sum_i s(i) x(i)$ jest sumą N niezależnych zmiennych gaussowskich, dlatego ma rozkład normalny pod każdą z hipotez i pozwala na ścisłą, analityczną kontrolę poziomu fałszywego alarmu poprzez wybór progu $\tau = z_{1-\alpha} \sigma \sqrt{N}$.

Po drugie, kluczową miarą jakości detekcji jest pojedyncza wielkość, efektywny stosunek sygnału do szumu $d = A\sqrt{N}/\sigma$, łącząca wszystkie trzy parametry wymienione w treści zadania. Trzy oddzielne rysunki (7, 8 i 9) różnią się jedynie wyborem osi poziomej, lecz każda krzywa na każdym z nich odpowiada określonej wartości d - to wyjaśnia, dlaczego wszystkie projekcje składają się w jedną uniwersalną krzywą na rysunku 11. Z tej obserwacji wynika praktyczna zasada projektowa: niedostatek w jednym parametrze można zawsze zrekomensować nadmiarem w innym, według reguły $A^2 N / \sigma^2 = \text{const}$.

Po trzecie, detekcja sygnału znacznie słabszego od szumu nie napotyka żadnej fundamentalnej bariery - jak pokazuje rysunek 13, nawet przy $A = 0,01\sigma$ wystarczająco długi sygnał pozwala uzyskać moc detekcji bliską jedności. Cena, jaką trzeba zapłacić, to kwadratowy wzrost długości sygnału względem odwrotności amplitudy. To właśnie dzięki tej

zasadzie pseudosumowy kod o długości N rzędu kilku tysięcy próbek pozostaje praktycznie niewykrywalny dla osoby trzeciej, która nie zna $s(i)$, lecz jest pewnie wykrywany przez odbiorcę dysponującego dopasowanym filtrem.

Po czwarte, wymóg bardzo niskiego prawdopodobieństwa fałszywego alarmu (rysunek 10) zwiększa konieczny SNR jedynie logarytmicznie, ponieważ kwantyl $z_{1-\alpha}$ rośnie bardzo wolno wraz ze spadkiem α . Przejście z $\alpha = 10^{-3}$ ($z_{1-\alpha} \approx 3,09$) do $\alpha = 10^{-6}$ ($z_{1-\alpha} \approx 4,75$) zwiększa wymagany efektywny SNR o niespełna dwa, co zwykle jest cenowo dostępne przez umiarkowane wydłużenie sygnału.

2.4 Koncepcja systemu telekomunikacyjnego

Sformułowany detektor stanowi w istocie odbiornik jednego bitu informacji - obecność sygnału alarmowego można utożsamić z bitem "1", brak alarmu z bitem "0". Ustalenie wartości krytycznej progu sprowadza się wtedy do problemu optymalizacji decyzji binarnej. W klasycznym podejściu Neymana-Pearsona, użytym powyżej, próg dobiera się tak, aby utrzymać zadany maksymalny koszt fałszywego alarmu, co odpowiada minimalizacji prawdopodobieństwa pominięcia sygnału przy ograniczeniu na P_{FA} . W podejściu bayesowskim, jeśli znane są prawdopodobieństwa apriori obu bitów π_0 i π_1 oraz koszty błędów obu rodzajów c_{10} i c_{01} , optymalny próg minimalizuje średni oczekiwany koszt i wynosi $\tau^* = \sigma^2/A \cdot \log(\pi_0 c_{10}/(\pi_1 c_{01})) + AN/2$. W symetrycznym przypadku równych prawdopodobieństw i kosztów ($\pi_0 = \pi_1$, $c_{10} = c_{01}$) wzór upraszcza się do $\tau^* = AN/2$, czyli środka między oczekiwanymi wartościami T pod obiema hipotezami - jest to klasyczne kryterium maksymalnego prawdopodobieństwa a posteriori.

Transmisja wielu bitów jednocześnie jest możliwa na kilka komplementarnych sposobów. Najprostszym jest sekwencyjne nadawanie - każdy bit kodowany przez osobne wystąpienie tego samego sygnału $s(i)$ lub jego inwersji ($+s$ dla "1", $-s$ dla "0"), co odpowiada schematowi modulacji BPSK z rozproszeniem widma. Alternatywnie można wprowadzić zestaw M wzajemnie ortogonalnych kodów $s_1, \dots, s_M$ (np. kody Walsha-Hadamarda lub Golda) i jednocześnie nadawać wszystkie M bitów jako sumę $\sum_k b_k s_k$, gdzie $b_k \in \{-1, +1\}$ koduje k -ty bit. Odbiornik dekoduje każdy bit niezależnie, licząc korelację $\sum_i s_k(i) x(i)$, ponieważ ortogonalność kodów zapewnia, że pozostałe składowe sumują się do zera w wartości oczekiwanej. Jest to ogólna idea systemu CDMA (Code Division Multiple Access), w którym wielu nadawców korzysta z tej samej szerokości pasma, lecz każdy używa innego, ortogonalnego kodu i odbiorcy potrafią je niezależnie rozdzielić.